

Neural-network Quantum States

李相 2019311574

2019 年 12 月 29 日

1 Introduction

本次课程作业的主要内容是重复了一篇题为“Solving the quantum many-body problem with artificial neural networks”的文章中的部分内容，该文章于2017年2月发表在《科学》杂志上。文章的主要工作是利用受限玻尔兹曼机来表示多体波函数，在训练的过程中利用了蒙特卡罗采样，并基于能量最低原理采用Stochastic Reconfiguration方法更新参数。文章提出的方法适用于经典的1维和2维自旋模型以及时间演化过程，我在课程作业中仅实现了1维的横场Ising模型方案，并计算了基态能量以及 $\langle \sigma_x \rangle$ 与 $\langle \sigma_z \rangle$ 的值，并与第二次作业中实现的DMRG方法的结果做对照。代码的实现过程参考了文章的Supplementary Material和Github网站上的项目“zeldredge/py-nqs”。

2 Model Details

Restricted Boltzman Mechine

受限玻尔兹曼机的每一种状态都有对应的能量 $E(\mathbf{v}, \mathbf{h})$ ，根据这个能量表达式，作者在文章中提出了利用受限玻尔兹曼机表示多体波函数的方法，

$$E(\mathbf{v}, \mathbf{h}) = - \sum_{i=1}^M \sum_{j=1}^N h_i w_{ij} \sigma_j^z - \sum_{i=1}^M b_i h_i - \sum_{j=1}^N a_j \sigma_j^z \quad (1)$$

$$\Psi_M(S; W) = \sum_{\{h_i\}} e^{-E(\mathbf{v}, \mathbf{h})} \quad (2)$$

其中 $S = \sigma_1^z, \dots, \sigma_N^z$ 是自旋体系的一个态， W 是受限玻尔兹曼机的所有参数。由于隐藏层参数 $h_i = \{-1, 1\}$ ，波函数的表达式可以化简为，

$$\Psi_M(S; W) = e^{\sum_{j=1}^N a_j \sigma_j^z} \times \prod_{i=1}^M G_i(S) \quad (3)$$

$$G_i(S) = 2 \cosh[b_i + \sum_j w_{ij} \sigma_j^z] = 2 \cosh[\theta_i(S)] \quad (4)$$

Average of an Operator

在利用受限玻尔兹曼机表示出多体波函数后，最重要的问题就是如何求出该波函数在某个自旋态下

的能量。以1维横场Ising模型为例，

$$H = - \sum_{i=1}^N g \sigma_i^x - \sum_{i=1}^{N-1} \sigma_i^z \sigma_{i+1}^z \quad (5)$$

$$\sigma_i^x | \dots, \uparrow, \dots \rangle = 1 \times | \dots, \downarrow, \dots \rangle; \sigma_i^x | \dots, \downarrow, \dots \rangle = 1 \times | \dots, \uparrow, \dots \rangle \quad (6)$$

$$\sigma_i^z \sigma_{i+1}^z | \dots, \uparrow, \downarrow, \dots \rangle = 1 \times (-1) \times | \dots, \downarrow, \uparrow, \dots \rangle \quad (7)$$

因此，对于一个算符 \hat{o} ，当它作用于一个自旋态 S ，则有 $\hat{o} * S = mel * S'$ 。于是，文章中计算该算符在 S 态下的平均值公式为，

$$\langle \hat{o} \rangle = mel \times \frac{\Psi(S'; W)}{\Psi(S; W)} \quad (8)$$

Training

我在训练模型时使用的初始自旋态为随机自旋态 S^0 ，通过蒙特卡罗采样的方法来生成之后的自旋态 S^1, \dots, S^p ，其中每次采样的接受概率为，

$$A(S^k \rightarrow S^{k+1}) = \min \left(1, \left| \frac{\Psi(S^{k+1}; W)}{\Psi(S^k; W)} \right|^2 \right) \quad (9)$$

在多次采样生成一条自旋态的马尔可夫链后，需要对受限玻尔兹曼机的参数进行更新，更新的公式参考文章的Supplementary Material，总结如下：

$$W(p+1) = W(p) - \gamma(p) S^{-1}(p) F(p)$$

其中 $\gamma(p)$ 是学习率， $S = S_{i,j}^{reg} = S_{i,j} + \lambda(p) \delta_{i,j} S_{i,i}$ ，并且

$$S_{i,j}(p) = \langle O_i^* O_j \rangle - \langle O_i^* \rangle \langle O_j \rangle \quad (10)$$

$$F_j(p) = \langle E O_j^* \rangle - \langle E \rangle \langle O_j^* \rangle \quad (11)$$

$$\lambda(p) = \max(\lambda_0 b^p, \lambda_{min}); \lambda_0 = 100, b = 0.9, \lambda_{min} = 10^{-4} \quad (12)$$

$$\begin{aligned} O_k(S) &= \frac{1}{\Psi(S; W)} \partial_W \Psi(S; W) \\ \frac{1}{\Psi(S; W)} \partial_{a_i} \Psi(S; W) &= \sigma_i^z \\ \frac{1}{\Psi(S; W)} \partial_{b_j} \Psi(S; W) &= \tanh[\theta_j(S)] \\ \frac{1}{\Psi(S; W)} \partial_{w_{ij}} \Psi(S; W) &= \sigma_i^z \tanh[\theta_j(S)] \end{aligned} \quad (13)$$

3 Results

在本次作业中，计算的Ising模型体系均为20个自旋。由于每改变一次外加磁场 g ，都需要重新训练一次模型，并且每次模型训练所需时间较长，仅选取了 $g = 0.01, 0.1, 0.5, 1.04$ 个值来简略观察外磁场的影响。另外，受限玻尔兹曼机有一个重要的参数 α ，是隐藏层节点个数（ $\{h_i\}$ 的个数）与输入层节点个数（ $\{\sigma_i^z\}$ 的个数，即自旋粒子数，在本次作业中均为20）之比。在原文中作者提到 α 的作用与DMRG方法中节点连接的维数 D_{max} 相同，由于 α 越大，模型训练所需时间越长，本次作业中仅选取了 $\alpha = 2, 4$ 来评估

结果。

首先定性看一下模型训练时的收敛情况，如图1与图2。




图 1: $\alpha = 2$




图 2: $\alpha = 4$

从图中可以看出， $\alpha = 4$ 时的收敛情况相比 $\alpha = 2$ 稍显平滑，但区别不大。体系能量与 $\langle \sigma_x \rangle$ 随外加磁场 g 的变化与实际相符合，但在 $g = 1.0$ 时 $\langle \sigma_z \rangle$ 的值仍远大于0说明了模型对 $\langle \sigma_z \rangle$ 的预测效果较差。如果确实如作者所说 α 的作用与DMRG方法中节点连接的维数 D_{max} 相同，可以尝试使用更大的 α 来训练。但由

于程序的隐藏bug，当 α 较大时会有数据溢出错误（推测是因为随机初始态不合理，在 α 较大时更容易出现数据溢出），暂时无法继续验证更大的 α 是否能让模型对 $\langle\sigma_z\rangle$ 的预测能力增强。

表 1: NQS模型与DMRG的计算结果对比

	Energy		$\langle\sigma_x\rangle$		$\langle\sigma_z\rangle$	
g	NQS	DMRG	NQS	DMRG	NQS	DMRG
0.01	-0.95001	-0.95003	0.00185	0.00500	1	1
0.1	-0.95118	-0.95275	0.03494	0.05037	0.99875	0.99872
0.5	-1.00863	-1.02001	0.40788	0.29318	0.90425	0
1	-1.24943	-1.25539	0.63523	0.72882	0.63450	0

接下来，定量对比一下 $\alpha = 4$ 时受限玻尔兹曼机模型的计算结果与DMRG的计算结果。从表1中的数据可以看出，在小数点后两位的精确度上，NQS模型与DMRG的基态能量的计算结果是一致的。二者 $\langle\sigma_x\rangle$ 的计算结果变化趋势是相同的，但具体结果有较大差异。NQS模型对 $\langle\sigma_z\rangle$ 的计算结果不可信。

4 Conclusion

本次课程作业参考实现了文献中的受限玻尔兹曼机模型，可以通过这样的神经网络来表示1维Ising模型的多体波函数，并可以利用神经网络量子态（NQS）计算不同算符的观测值。与其他机器学习类似，NQS预测多体波函数可观测值所需的时间很短，但却需要更多的时间来训练出合适的神经网络模型参数。同样的，由于NQS在训练过程中只考虑了基态能量最低，它在预测其他物理量时的表现略有不足。虽然如此，文章提出的NQS模型仅用三层的受限玻尔兹曼机网络能够达到现在的精确度，也是启发我们深度神经网络、卷积神经网络等在解决多体问题时能够有更好的表现。